

Intermediate Top-K에서 토큰별로 선택되는 뉴런은 얼마나 겹치는가

모델 LLaMA2-7B (d = 11008) 데이터 wikitext-2 test, 32 × 2048 tokens 잡 20260724-173030 · a6000-4

일자 2026-07-24

FFN의 intermediate activation $\mathbf{i} = \mathbf{u} \odot \mathbf{g}$ 를 토큰별 magnitude Top-K로 sparsify할 때, 토큰마다 살아남는 뉴런 집합이 서로 얼마나 일치하는지를 실제 sparsified inference에서 측정했다. 질문은 하나다 — sparsity가 50% → 70% → 90%로 죄어질수록 "계속 살아남는 중요한 뉴런"으로 선택이 수렴하는가, 아니면 토큰마다 다른 뉴런을 중요하다고 고르는가.

1 지표 정의

토큰 t 의 intermediate 벡터에서 Top-K 후 0이 아닌(살아남은) 뉴런 인덱스 집합을 $\mathbf{S}_t$ 라 한다. 목표 유지 개수는 $K = \lfloor (1-s) \cdot d \rfloor$ (s : 목표 sparsity, $d = 11008$).

K_{eff} — 토큰당 실제 생존 뉴런 수

$$K_{\text{eff}} = (1/N) \sum_t |\mathbf{S}_t| \quad (N = \text{전체 토큰 수})$$

의미: 마스킹이 목표대로 걸렸는지 확인하는 값. 목표 K 와 거의 같아야 정상이며, bf16에서 $|i_j|$ 가 동률(tie)이면 몇 개 더 남을 수 있다. 실측: 5513/3312/1106 vs 목표 5504/3302/1100 — 오차 $\leq 0.5\%$.

$C(\delta)$ — 거리 δ 토큰 쌍의 겹침 비율 (containment overlap)

$$C(\delta) = E_t[|\mathbf{S}_t \cap \mathbf{S}_{t+\delta}|] / K_{\text{eff}}$$

의미: 토큰 t 가 유지한 K 개 뉴런 중, δ 칸 뒤 토큰도 유지한 비율. **1**이면 두 토큰이 완전히 같은 뉴런을 고른 것, **chance 수준**이면 서로 무관하게 고른 것. "인접 토큰 겹침"은 $C(1)$ 이다.

C_{rand} — 무작위 토큰 쌍의 겹침 비율

$$C_{\text{rand}} = E_d[|S_t \cap S_{\pi(t)}|] / K_{\text{eff}} \quad (\pi: \text{시퀀스 내 무작위 순열})$$

의미: 위치상 아무 관련 없는 두 토큰(같은 2048-토큰 문맥 안)의 겹침. $C(\delta)$ 가 C_{rand} 보다 큰 만큼이 순수한 "이웃 효과"이고, C_{rand} 가 chance보다 큰 만큼이 문맥 전체가 공유하는 구조다.

chance — 무구조 기준선 (독립 무작위 선택 시 기대 겹침)

$$\text{chance} = K_{\text{eff}} / d$$

유도: 각 토큰이 d 개 중 K 개를 서로 독립적으로, 균일하게 고른다면 특정 뉴런 j 가 상대 집합에 있을 확률이 K/d 이므로 $E|S_t \cap S_{t'}| = K \cdot (K/d)$, 이를 K 로 나누면 K/d . **의미:** 겹침의 바닥값. 공유 구조가 전혀 없어도 이만큼은 겹친다. 따라서 모든 겹침 값은 절대값이 아니라 **chance 대비 몇 배(×)인지**로 읽어야 한다. s 가 높을수록 K/d 가 작아져 ($0.50 \rightarrow 0.30 \rightarrow 0.10$) 같은 절대 겹침도 더 큰 구조를 뜻한다.

freq_j, always-on, Gini — 뉴런별 선택 빈도의 구조

$$\text{freq}_j = (1/N) \sum_t \mathbb{1}[j \in S_t]$$

의미: 뉴런 j 가 전체 토큰 중 선택된 비율. **always-on**은 $\text{freq}_j > 0.9$ 인 뉴런의 비율(모든 토큰이 공유하는 고정 중요 집합의 크기), **Gini**는 freq 분포의 불평등도(0 = 모든 뉴런이 균등하게 쓰임, 1 = 극소수에 집중). **union**은 한 시퀀스(2048토큰)가 사용한 뉴런 합집합 $|\cup_t S_t| / d$.

2 결과 — 겹침은 chance의 몇 배인가

$s=0.9$ 인접 토큰 겹침

3.15× chance

$C(1) = 0.316$ vs chance 0.100

$s=0.9$ 무작위 쌍 겹침

1.86× chance

$C_{\text{rand}} = 0.187$ — 절대값은 19%뿐

always-on 뉴런 ($s=0.9$)


0.04%

모든 토큰이 공유하는 고정 집합은 사실상 없음

시퀀스당 뉴런 사용률

100%

2048토큰이 11008개 뉴런 전부 사용



토큰 거리 δ 에 따른 겹침 $C(\delta)$ 와 무작위 쌍 C_{rand} (32개 layer 평균). 점선은 각 s 의 chance. 인접($\delta=1$)의 초과 겹침은 $\delta \approx 16$ 안에서 대부분 소멸하고, 그 뒤로는 무작위 쌍 수준으로 수렴한다.

수치 표 (chart 데이터)

s	K_{eff}	chance	C(1)	C(4)	C(16)	C(64)	C(256)	C_{rand}
0.5	5513	0.501	0.575 1.15×	0.539	0.531	0.527	0.525	0.524 1.05×
0.7	3312	0.301	0.434 1.44×	0.374	0.359	0.352	0.348	0.347 1.15×
0.9	1106	0.100	0.316 3.15×	0.232	0.208	0.197	0.190	0.187 1.86×

선택 빈도의 구조

s	always-on (freq>0.9)	rare (freq<0.01)	never	Gini	union / 시퀀스
0.5	0.96%	0.00%	0.00%	0.092	1.000
0.7	0.57%	0.00%	0.00%	0.156	1.000
0.9	0.04%	0.34%	0.00%	0.307	1.000

Gini가 0.09 → 0.31로 오르는 것은 s 가 죄어질수록 빈도 분포가 기울어진다는 뜻이지만, 절대 수준은 여전히 낮다(참고: 극단적 집중이면 0.7+). layer 31만 예외적으로 집중이 강하다 — $s=0.9$ 에서 Gini 0.705, $s=0.5$ 에서 always-on 10.1%.

3 생존자 분석 — "중요한 뉴런"의 정체성은 s가 바뀌어도 유지되는가

각 s에서 가장 자주 선택된 상위 10% 뉴런 집합(freq_j 기준 top 10%)을 뽑아, s 간에 그 집합이 얼마나 겹치는지 보았다. 서로 무관하면 겹침은 0.100(전체의 10%)이어야 한다.

비교	top-10% 집합 겹침	chance	freq 벡터 상관 (Pearson)
s=0.5 vs 0.7	0.907	0.100	0.980
s=0.7 vs 0.9	0.760	0.100	0.908
s=0.5 vs 0.9	0.678	0.100	0.820

"자주 뽑히는 뉴런"이라는 개념 자체는 sparsity 수준이 바뀌어도 일관된다 (chance의 7–9배 겹침). 즉 빈도 상위 풀은 실재한다 — 다만 아래 해석처럼, 그 풀이 개별 토큰의 선택을 지배하지는 못한다.

4 해석

답: 둘 다 맞지만, 지배적인 것은 토큰 의존성이다. s가 높아질수록 겹침은 chance 대비 뚜렷하게 커지고(1.15x → 3.15x) 자주 뽑히는 뉴런 풀도 s 간에 일관되지만, 절대 겹침은 낮다 — s=0.9에서 인접 토큰조차 선택의 68%가 서로 다르고, 무작위 쌍은 81%가 다르다. 모든 토큰이 공유하는 고정 중요 집합(always-on)은 사실상 없고, 한 시퀀스는 뉴런 전체를 사용한다. intermediate 뉴런의 중요도는 본질적으로 문맥 의존적(contextual)이다.

- 이웃 효과는 초단거리다. C(δ)의 초과분은 $\delta \approx 16$ 안에서 대부분 사라지고 C_{rand} 로 수렴한다. 인접 토큰끼리의 mask 재사용도 $\delta \leq 4$ 수준에서만 의미가 있다.
- block-shared mask(RB-Sparse류)에 대한 경고. 토큰 간 mask를 공유하면 s=0.9 기준 인접에서도 per-token 신호의 ~68%를 잃는다. 공유 mask 설계는 "공유 가능한 얇은 백본 + per-token 잔차" 형태가 아니면 성립하기 어렵다.
- layer 31은 예외. 출력 직전 layer에는 heavy-hitter가 실재한다 (Gini 0.705). layer별 차등 전략(마지막 layer만 고정 집합 + 나머지는 동적)의 여지.
- 이 결과는 contextual sparsity 문헌(Deja Vu 계열)의 관찰과 정합한다.

재현: `repo aiha-choij/EfficientAI, tag exp/2026-07-24_larosa-llama2-topk-overlap · scripts/analyze_topk_overlap.py --sparsities 0.5,0.7,0.9 --nsamples 32 --attn sdpa` · 선택 집합은 실제 sparsified forward의 down_proj 입력 hook에서 수집(≠ dense 활성화 기준). 원자료: a6000–

4:~/workspace/analysis/llama2_topk_overlap.pt. 한계: 단일 모델(LLaMA2-7B)-단일 데이터(wikitext-2)·32×2048 토큰; C_{rand} 는 시퀀스 내 쌍만 비교(문서 간 쌍 미포함).