

Mean-gate residual 분해 검증 — LLaMA2-7B

FFN intermediate activation을 "선형 성분 + residual"로 분해하면 더 높은 sparsity에서 정확도를 지킬 수 있는가. 분포 지표(Phase 0)부터 조건 C0-C5의 wikitext-2 PPL 메인 테이블(Phase 3-4)까지의 전체 결과 리포트.

모델 LLaMA2-7B (h=4096, d=11008, 32층)	잡 050-20260723-155254	코드 스냅샷 exp/2026-07-22_oracle-llama2-phase0-calib (6bf95b1)
실행 a100-40-2 · GPU 1장 · 440분		

● PARTIAL-GO

H1 확증 — 정확 보상 조건 C3가 같은 sparsity에서 C1의 열화를 34/39/**56%** 줄였습니다 (s=0.9: PPL 8.110 → **6.638**). **H2 기각** — score 교정(C2)만으로는 이득 없음: 개선은 전부 보상 항의 몫. **H3는 rank 문제** — M의 스펙트럼이 flat해서(90% 에너지에 $r \approx 1,270$ 필요) $r=512$ 보상은 붕괴하고, **plain 균일 $r=1024$** 가 최선의 배포형(s=0.9 PPL 7.229, +6.2% 연산). whitening·rank 배분은 역효과로 보류. 남은 결정: **$r=2048$ 수렴 테스트 vs 출력측 가중 설계.**

1 실험이 검증하려는 것

gated MLP의 FFN 출력은 $y = W_d(u \odot g)$ 로, intermediate $i = u \odot g$ 의 sparsity를 활용하면 FFN의 세 linear를 모두 건너뛸 수 있다. 직전 실험(Top-K)에서 $|i|$ 기준 마스킹만으로도 50% sparsity에서 $\Delta PPL +0.047$ 로 거의 무손실임을 확인했다. 이번 실험 라인은 여기서 한 발 더 나간다:

$$y = \sum_j u_j g_j W_d[:, j] = Mx + \sum_j u_j (g_j - \bar{g}_j) W_d[:, j] \quad \text{여기서 } M = W_d \cdot \text{diag}(\bar{g})$$

gate를 calibration 평균 $\bar{g}$ 로 근사한 선형 성분 Mx 를 떼어내면, 남는 것은 residual $r = u \odot (g - \bar{g})$ 뿐이다. **H1**: r의 분포가 i보다 집중되어 있다면, 같은 유효 연산량에서 더 높은 sparsity로 정확도를 유지할 수 있다. **H3**: 배포 가능하려면 M의 rank-r 근사(여기선 $r=512=h/8$)가 이 이득을 잠식하지 않아야 한다. 전체 검증은 oracle 세팅(마스크를 실제 activation에서 계산, 전체 계산 후 마스킹 시뮬레이션)의 조건 사다리로 진행한다:

조건	score (top-p 대상)	출력 계산식	성격
C0	—	dense	기준선
C1	$ i_j $	$W_d(moi)$	기존 Top-K의 top-p판
C2	$ i_j \cdot \ W_d[:, j]\ $	C1과 동일	weight-aware (H2)
C3	$ r_j \cdot \ W_d[:, j]\ $	$W_d(moi) + W_d((1-m)\odot\tilde{g}\odot u)$	정확한 보상 — 진단용
C4	C3과 동일	$W_d(moi) + B(Ax) - W_d(m\tilde{g}\odot u)$	rank-512 배포형 (H3)
C5	C3, $\tilde{g} \rightarrow \tilde{g}^*$	C3, $\tilde{g} \rightarrow \tilde{g}^*$ (u^2 -가중 평균)	가중 평균 변형

이번 잡(Phase 2)이 수행한 것

조건별 PPL sweep에 GPU를 쓰기 전, 분포 지표만으로 H1의 조기 go/no-go를 판정하고 이후 phase의 재료를 전부 만들어 두는 잡이다. 파이프라인 세 단계:

1. **Calibration** — 코퍼스 2종(c4-en, wikitext-103) 각 512 시퀀스 $\times$ 2048 토큰에서 뉴런별 $\tilde{g}$, $\tilde{g}^*$, $E[g^2]$ 를 fp32/fp64 누적으로 추정. c4 스트리밍이 정상 동작해 **primary = c4**, wikitext-103은 $\tilde{g}$ 안정성 대조용.
2. **Phase-0 분포 리포트** — calibration 시퀀스 32개 위에서 층별로 i와 r 각각의 top-p 유도 sparsity ($p \in \{0.7, 0.8, 0.9, 0.95, 0.99\}$), Hoyer, kurtosis, gate 통계, $\tilde{g}$ 코퍼스 간 Pearson 상관을 계산.
3. **M 구성 + SVD** — 층별 $M = W_d \cdot \text{diag}(\tilde{g}) \cdot W_u$ (4096 $\times$ 4096)를 만들고 rank-512 인자 A, B를 저장 (C4 sweep의 입력). 층별 Frobenius 에너지 보존율 기록.

판정 기준(사전 등록): 같은 p에서 r의 유도 sparsity 곡선이 i 곡선 위에 있으면 H1 go 신호. 평가는 이후 phase에서 기존 wikitext-2 PPL 파이프라인으로 진행 (Top-K 결과와 직접 비교).

2 결과

이 절의 지표

유도 sparsity	top-p 마스크가 실제로 잘라낸 뉴런 비율 $1 - \text{mean}(m)$. top-p는 score 내림차순 누적합이 전체의 $p \times 100\%$ 가 되는 지점까지 보존 — 같은 p에서 유도 sparsity가 높을수록 분포가 소수 뉴런에 집중되어 있다는 뜻 (H1의 직접 지표).
Hoyer	$(\sqrt{d} - \ v\ _1 / \ v\ _2) / (\sqrt{d} - 1) \in [0, 1]$. 벡터가 완전 균등하면 0, 원소 하나만 남으면 1 — 집중도가 높을수록 크다.
kurtosis	$E[(v-\mu)^4] / \text{Var}(v)^2$. 꼬리가 두꺼울수록(=소수의 큰 값에 질량이 몰릴수록) 크다. Hoyer와 함께 "집중" 주장의 보조 지표.
CV²	뉴런별 gate 변동성 $\text{Var}(g_j) / E[g_j]^2$. 크면 "평균 gate $\tilde{g}_j$ "가 실제 g_j 를 잘 대표하지 못한다 — 보상 근사가 성립하기 어려운 구간의 신호.

$\bar{g}$ Pearson

서로 다른 calibration 코퍼스(c4 vs wikitext-103)로 추정된 $\bar{g}$ 벡터 간 상관. 1에 가까울수록 $\bar{g}$ 가 코퍼스 불변의 "모델 상수"라는 뜻.

r이 i보다 집중된 층

30 / 32

역전: 층 30, 31번

평균 유도 sparsity 격차 (p=0.9)

+3.0%p

중간층 최대 +5.3%p

$\bar{g}$ 코퍼스 Pearson 최소

⚠ 0.48

층 2 · 초반 층에서 불안정

r=512 에너지 보존 최소


⚠ 0.54

층 7 · Frobenius 기준

유도 sparsity 곡선 — r vs i (32층 평균)

같은 top-p 노브에서 유도되는 sparsity의 토른·층 평균. 모든 p에서 r 곡선이 i 곡선 위 = H1 go 신호.

— $i = u \odot g$ — $r = u \odot (g - \bar{g})$




층별 진단 3종 (x축 공유: 층 0 → 31)

① r-i 유도 sparsity 격차(p=0.9) · ② $\bar{g}$ 의 c4↔wikitext-103 Pearson 상관 · ③ rank-512가 보존하는 M의 Frobenius 에너지


① $r - i$ 유도 sparsity 격차 @ $p=0.9$ (%p)



② $\bar{g}$ Pearson ($c4 \leftrightarrow \text{wikitext-103}$)




③ M의 Frobenius 에너지 보존율 (rank 512)



크기 분포 히스토그램 — $|i|$ vs $|r|$ (대표 5개 층, calibration 8 시퀀스 = 층당 1.8억 값)

x축 $\log_{10}|v|$ ($-6 \rightarrow 2$), y축 bin당 비율. 곡선이 왼쪽으로 이동 = 값이 0 쪽으로 쏠림. 세로 눈금은 각 분포의 중앙값.

— $|i| = |u \odot g|$ — $|r| = |u \odot (g - \bar{g})|$



히스토그램 판독. 확인하려던 현상 — r 의 질량이 i 보다 0 쪽으로 쏠려 있는가 — 은 5개 층 모두에서 관찰된다: r 곡선(주황)이 i 곡선(파랑) 대비 왼쪽으로 이동해 있고, 중앙값 비 $\text{med}|r|/\text{med}|i|$ 는 층 7에서 **0.640**, 층 16에서 0.659로 격차가 최대이며(유도 sparsity 격차가 최대인 구간과 일치), 층 24(0.841) → 층 31(0.924)로 갈수록 1에 접근한다 — 층별 진단에서 본 "후반 층에서 이득 소멸"의 분포 버전이다. 이동 폭 자체는 크지 않은데(중앙값 기준 ~1.5 배), 이는 평균 유도 sparsity 격차가 +3%p 수준인 것과 일관된다.

읽는 법. 세 패널이 같은 이야기를 층 축에서 보여준다. 격차(①)는 층 6-18에서 +4.5~+5.3%p로 가장 크고 층이 깊어질수록 줄다가 층 30(-0.2%p)·31(-2.6%p)에서 음수로 뒤집힌다. 이 뒤집힘은 gate 변동성과 정확히 겹친다 — 후반 층은 $\text{CV}^2(= \text{Var}(g)/\text{E}[g]^2)$ 중앙값이 40을 넘어, "평균 gate"라는 근사 자체가 성립하지 않는 구간이다. 반대로 M의 저rank성(③)은 후반 층에서만 좋다(층 31은 0.985). 즉 **보상이 잘 되는 곳과 residual이 집중되는 곳이 서로 다른 층**이라는 것이 이 실험의 구조적 발견이다.

보조 지표도 방향이 일치한다: Hoyer-kurtosis는 총 31 하나를 제외한 전 층에서 r이 우세하고, 보상이 항별로 이기는 비율 $P(|g-\bar{g}| < |g|)$ 은 전 층에서 0.5를 넘는다(0.54-0.68).

▶ 층별 전체 수치 테이블 (32층 × 11지표)

3 Phase 3-4: PPL 메인 결과

선택 방식은 **top-K** ($K = \text{int}((1-s) \cdot d)$), 기존 Top-K 실험과 동률 처리까지 동일 — C1이 기존 세팅의 정확한 재현이 되도록; 2026-07-23 결정). Phase 3 게이트에서 dense 5.4738, C1 5.5216/5.7284/8.1096으로 기존 anchor를 소수 4자리에서 재현(최대 Δ 0.0013, GPU A100→A6000·attention flash→sdpa 변경에도) — 이후 조건 간 ~0.01 이상의 차이는 전부 실제 신호다.

이 절의 지표


- top-K 선택**토크마다 score 상위 $K = \lfloor (1-s) \cdot d \rfloor$ 개 뉴런만 보존 (s = 잘리는 비율, $d = 11008$). 모든 토크가 정확히 같은 연산량을 갖게 되어, 조건 간 비교가 "같은 연산량에서 누가 덜 읽는가"가 된다.
- PPL**perplexity $\exp(\text{평균 next-token NLL})$ — wikitext-2 test, 문맥 2048. 낮을수록 좋고, dense(5.4738)가 하한. 언어모델 품질의 연속 지표.
- Δ PPL** $\text{PPL}(\text{조건}) - \text{PPL}(\text{dense})$. sparsification이 유발한 열화량. 조건 비교는 같은 s 에서 Δ PPL이 작은 쪽이 승.
- 유효 연산 비율**FFN 연산의 잔존 비율. C1-C3/C5는 $(1-s)$, C4는 rank-r 보상 브랜치 비용을 더해 $(1-s) + 2r/(3d)$ ($r=512 \rightarrow +3.1\%$, $1024 \rightarrow +6.2\%$, $2048 \rightarrow +12.4\%$).

s	C0 dense	C1 i	C2 +coln	C3 보상(정확)	C4 r=512	C5 $\bar{g}^*$
0.5	5.4738	5.5216	5.5210	5.5051	6.2537	5.5144
0.7	5.4738	5.7284	5.7611	5.6283	6.5563	5.6665
0.9	5.4738	8.1096	8.2759	6.6381	8.7638	6.8889

측정 sparsity는 전 런에서 s 와 일치(± 0.0001). C3는 배포 불가능한 진단 조건(자른 뉴런의 u 를 실제 계산해야 함); 배포형은 C4이며 rank 항의 추가 연산 $2r/3d$ ($r=512 \rightarrow +3.1\%$)가 붙는다.

Δ PPL vs sparsity — 조건별 (log 스케일)

dense 대비 PPL 증가분. 아래에 있을수록 좋다. C3(보상)가 전 구간 최저, C4($r=512$)는 보상 근사 오차로 최악.



판독. ① H1 확증 — C3의 ΔPPL은 +0.031/+0.155/+1.164로 C1(+0.048/+0.255/+2.636)의 열화를 s=0.9에서 56% 줄인다. mean-gate 분해는 정확도 축에서 s=0.9 기준 ~1.5 PPL의 가치가 있다. ② H2 기각 — C2는 s=0.5에서 C1과 동률, 0.7/0.9에서는 오히려 나쁘다. 즉 C3의 이득은 score 교정이 아니라 전적으로 보상 항에서 온다. ③ H3 부분 실패 — C4(r=512)는 전 구간에서 C1보다도 나쁘다. 보상이 거의 필요 없는 s=0.5에서조차 +0.78 PPL이 없었는데, 이것이 바로 $(\hat{M}-M)x$ 근사 오차의 기저 비용이다 — Phase 0에서 경고한 "중간층 Frobenius 에너지 54-60%"가 그대로 현실화됐다. ④ C5($\tilde{g}^*$)는 C3보다 일관되게 조금 나쁘다 — 단순 평균 $\tilde{g}$ 가 더 나은 보상 상수다.

C4 개선 라운드 — whitening × rank × 배분 분해 (2026-07-24)

C4 붕괴의 원인 후보 (a) M 스펙트럼이 flat vs (b) plain SVD가 입력 분포를 무시 — 를 가리기 위해 두 가지 분해 방식을 같은 rank 예산에서 맞붙였다. 두 방식은 "무엇을 잘 근사할 것인가"라는 목적함수가 다르다:

	plain SVD	whitened SVD
목적함수	$\min \ \hat{M}-M\ _F$ (행렬 자체)	$\min E_x \ \hat{M}-M\ _2^2$ (실입력 위 출력)
구성	$SVD(M) \rightarrow B=U\sqrt{S}, A=\sqrt{S}\cdot V^T$	$SVD(M\cdot C), C=chol(\Sigma+\epsilon I) \rightarrow A에 C^{-1}$ 흡수
방향 가중	모든 입력 방향 동등 (Eckart-Young 최적)	입력 분산 λ_k 에 비례 — 자주 크게 오는 방향 우대
직관	"행렬을 잘 베킨다"	"자주 오는 입력에서 출력을 잘 맞춘다"
가정	모든 방향이 동등하게 중요	입력 분산 = 중요도 (이번 실험이 기각한 가정)

층별 rank 배분(τ -기준 에너지, 예산 모드는 τ 이분탐색)까지 더해 2×2+배분으로 분해한 결과:

s	C3 (참조)	plain r512	wht r512	plain r1024	wht r1024	alloc r1024	alloc r512	alloc r256
0.5	5.5051	6.2537	6.4859	5.7365	5.7668	5.9570	7.0903	9.2926
0.7	5.6283	6.5563	6.8483	5.9152	5.9638	6.1641	7.4886	10.0913
0.9	6.6381	8.7638	9.7606	7.2294	7.3974	7.6336	10.2638	17.4118

분해 결과. ① rank만이 유효한 지렛대 — plain 균일 r 512→1024로 -0.52/-0.64/-1.53 PPL. plain r1024가 최고의 C4: s=0.9에서 C1(8.11)을 이기고 C3와의 격차가 +0.23/+0.29/+0.59로 줄어든다 (추가 연산 2r/3d =

+6.2%). ② **whitening은 해로움** — 자기 목적함수(실측 입력 기준 $E \| (M - M)x \|^2$)는 13% 줄었는데 PPL은 모든 rank에서 악화(r512에서 s=0.9 +1.00). 입력 분포 L2가 downstream 손실과 정렬되지 않는다는 증거 — 저분산 (outlier성) 방향이 출력에 중요할 가능성. ③ **에너지 기반 배분도 해로움** — 같은 예산에서 균일 rank에 전패 (τ -배 분이 초·중반 층을 굵김: 예산 256에서 최소 r_l=5). 원인 판정: (a) flat 스펙트럼이 맞고, (b)는 기각 — whitening 과 τ -배분은 보류(추후 adaptive rank allocation 연구 시 재검토).

해석을 뒷받침하는 분석 3종 (2026-07-24 확정)


이 절의 지표 — 의미와 수식

보상 오차 (trunc_err)	$E_x \ (\hat{M} - M)x \ ^2$ — rank-r 근사 $M \approx BA$ 가 원래 보상행렬 M 을 대신할 때, calibration 입력 x 위에서 생기는 오차 벡터의 평균 크기. 본문에서 "입력측 L2"는 정확히 이 값이다 (L2 = 벡터의 유클리드 노름 $\ \cdot \ _2$).
tail 크기 (tail_norm)	$E \ ((1-m) \odot (\hat{g} \odot u)) \cdot W_d^T \ ^2$ — 운영점 s 에서 잘린 뉴런들의 몫, 즉 보상이 대체해야 할 신호의 크기.
trunc/tail 비	보상 오차 ÷ 대체 신호. 1에 가까우면 "신호만큼 큰 노이즈를 얻는" 보상이라 쓸모가 없고, 0에 가까울수록 깨끗한 보상.
누적 에너지 · r90	M 의 특이값 $S_1 \geq S_2 \geq \dots$ 에 대해 rank r 까지의 에너지 비율 $\sum_{k \leq r} S_k^2 / \sum_k S_k^2$. r90 = 이 값이 0.9에 도달하는 최소 r . r90가 크다 = 스펙트럼이 flat하다 = 저rank 근사가 본질적으로 어렵다.
D1-D10 (분산 십분위)	입력 자기상관 $\Sigma = E[xx^T]$ 을 고유분해하면 입력 공간의 직교 방향 4096개와 각 방향의 입력 분산 λ_k 가 나온다. 이를 λ 오름차순으로 10등분한 것이 D1(입력 분산 최저 10% 방향) ... D10(최고 10%). 각 방향에서의 보상 오차는 $n_k = \ (\hat{M} - M)v_k \ ^2$.
whitening의 목적	보상 오차의 기대값은 $E \ (\hat{M} - M)x \ ^2 = \sum_k \lambda_k \cdot n_k$ 로 분해된다 — 즉 whitening($M \cdot C$ 에 SVD, $C = \text{cholesky}(\Sigma)$)은 입력 분산 λ 가 큰 방향의 오차를 우선적으로 줄이도록 rank 예산을 재배치하는 것과 같다.

① "flat 스펙트럼이 원인" — 스펙트럼을 직접 보면. 아래 곡선이 각 층 M 의 rank별 누적 에너지다. r=512(첫 세로 선)에서 중간층(7·16·24)은 에너지의 54-67%밖에 못 담는다 — **M 의 1/8 rank로는 M 을 표현할 수 없다는 것**이 C4 붕괴의 직접 원인이다. r=1024에서 78-85%로 올라오는 것이 PPL 회복(8.76→7.23)과 맞물린다. 90% 도달 rank(r90)는 층 평균 1,270, 중간층 1,400-1,500 (h=4096의 ~35%). 유일한 예외가 후반 층(31: r90=92)인데, 이 예외가 아래 ③의 배분 실패와 연결된다.

M 의 누적 스펙트럼 에너지 vs rank (plain SVD, 대표 5개 층)


x축 rank(log), y축 누적 에너지 $\sum_{k \leq r} S_k^2 / \sum S_k^2$. 세로 점선 = r=512/1024/2048, 가로 점선 = 90%. 곡선이 오른쪽으로 누울수록(=늦게 올라갈수록) flat한 스펙트럼.



② "입력측 L2는 잘못된 지표" — 오차를 방향별로 분해하면, whitening은 보상 오차 $E \| (M - \hat{M})x \|$ 를 32층 전부에서 줄였다(-12%~-37%). 그런데 PPL은 모든 rank에서 나빠졌다. 모순처럼 보이는 이 결과는 오차를 어느 방향에서 줄였는지를 보면 풀린다: 아래 도표(층 16, $r=512$)에서 whitened의 오차는 D10(입력 분산 최고 방향)에서만 절반으로 줄고, D1-D8에서는 오히려 plain보다 크다. 5개 표본 층 전부 같은 패턴(D10 비율 0.47-0.57, D1 비율 1.13-1.22)이다. 오차 총량(가중합)은 줄었지만 저·중분산 방향의 오차는 늘어난 상태에서 PPL이 악화 → 손실에 중요한 신호가 저·중분산 방향에 산다는 결론이 따라온다. 입력 분산으로 중요도를 매기는 가중(whitening)은 정확히 중요한 방향을 희생하는 것이다.

방향별 보상 오차 n_k — 분산 십분위별 평균 (층 16, $r=512$)

D1 = 입력 분산 최저 10% 방향, D10 = 최고 10%. whitened(주황)는 D10만 싸게 사고 D1-D8에 오차를 전가한다. 나머지 4개 표본 층도 동일 패턴.




③ "rank가 유효 지렛대" — 지표와 PPL의 정합성 지도. 아래 산점도는 다섯 변형의 (trunc/tail 비, PPL)이다. 같은 기하 안에서는 지표가 PPL을 정확히 예측한다: plain 512→1024로 비가 0.586→0.385로 줄고 PPL도 8.76→7.23으로 따라 내려간다(파란 화살표). 그러나 기하를 건너면 역전된다: wht1024는 전 변형 중 최저 비(0.319)인데 PPL은 plain1024보다 나쁘다. 즉 입력측 L2는 "같은 분해 방식 안에서 rank를 비교"할 때만 유효한 지표다 — rank 증가는 이 지표가 유효한 유일한 축이고, 실제로 PPL을 움직인 유일한 지렛대였다. 부가 교정: τ -배분(alloc1024)의

최악 층은 31 (trunc/tail 0.96 vs 균일 0.56) — whitened 에너지 지표가 층 31을 "r90=30짜리 저rank"로 선언해 rank를 빼앗았지만, ①에서 봤듯 그 층 보상의 절대 정확도는 여전히 필요했기 때문이다.

입력측 L2 지표(trunc/tail 비) vs 실제 PPL — 변형 5종 @ s=0.9

지표가 PPL을 예측한다면 모든 점이 우상향 단조 배열이어야 한다. plain 계열(파랑)은 단조; whitened 계열(주황)은 지표가 더 좋는데 PPL이 더 나쁜 역전.



4 Phase-0 단서 회고와 다음 단계

Phase 0이 남긴 단서 세 가지 중 하나가 그대로 현실화됐고, 둘은 다음 라운드의 지렛대로 남아 있다:

⚠ 단서 3 (rank) — 현실화됨

"rank 512가 중간층 M의 Frobenius 에너지 54-60%만 보존" → Phase 4에서 C4가 C1 아래로 붕괴하는 것으로 확인. C4 – C3 격차 0.75/0.93/2.13 (s=0.5/0.7/0.9). r 증가가 1순위 지렛대: r=1024는 연산 +6.2%, r=2048은 +12.4% (2r/3d 기준).

⚠ 단서 1 (마지막 두 층 역전) — 미검증

층 30·31은 r이 i보다 퍼져 있다. `exclude_layers=[30,31]` 변형은 아직 안 돌렸다 — C3가 이미 크게 이기므로 우선순위는 내려갔지만, C4 rank sweep과 결합하면 배포형의 여지를 더 벌 수 있다.

⚠ 단서 2 (g 코퍼스 민감성) — 잔존 리스크

초반 층의 g가 코퍼스에 민감(Pearson 0.48-0.53)한데도 C3가 크게 이겼다 — 보상이 calibration 노이즈에 어느 정도 강건하다는 간접 증거. wikitext-g로 C3를 재실행하면 정량 확인 가능(미실행).

개선 방안 제안 — activation sparsity · PTQ 문헌 기반 (2026-07-24)

문제 구조: mean-gate 분해의 배포 비용은 M_x 의 full 계산(h^2 MAC = FFN의 12.4%)이고, 이를 줄이려는 rank-r 근사(C4)는 flat 스펙트럼 때문에 PPL을 잃는다. PTQ 문헌은 정확히 같은 구조의 문제 — "큰 선형 항을 싸게 계산 하되 오차를 통제" — 를 십 년째 다뤄왔고, 세 가지 이식 가능한 템플릿이 있다:

제안 1 — rank 대신 정밀도를 잘라라: full-rank 저비트 M (+ 저rank 오차 재구성) · 유력

템플릿: LQER(ICML'24) — $W \approx Q + AB$: 가중치를 저비트로 양자화(Q)하고 양자화 오차만 저rank(AB)로 재구성해 near-lossless W4A8 달성. ASER도 같은 구조(+ 오차항 whitening SVD).

이식: M을 rank로 자르지 말고 **full-rank 그대로 W4/W8 양자화**. 근거는 이번 십분위 분석 — rank 절단은 특정 방향(저분산 포함)을 **구조적으로 제거**하지만, 양자화 노이즈는 방향에 대해 비구조적(≈등방)이라 "저분산 방향이 중요하다"는 발견과 충돌하지 않는다. 비용: h^2 MAC은 유지(+12.4%, $r=2048$ 과 동일)하되 int4 연산·메모리 4-8×↓. 필요 시 잔여 양자화 오차를 $r \approx 64$ 수준의 fp 저rank로 재구성(LQER식).

검증 실험(오라클 시뮬, 코드 소폭): M을 RTN/GPTQ-4bit로 양자화해 C4 재실행 ×3s. 성공 기준: $s=0.9$ 에서 $C3 + 0.1$ 이내.

제안 2 — 뉴런 단위 sparse + low-rank 분해 (LoSparse 템플릿)

템플릿: LoSparse(ICML'23) / SSLC — $W = UV$ (공유 부분공간) + S (뉴런별 잔차): low-rank가 못 담은 "비일관 (incoherent)" 성분을 구조적 sparse로 보존.

이식: M은 뉴런별 rank-1 합 $M = \sum_j \tilde{g}_j \cdot W_d[:,j] \cdot W_u[j,:]$ 이다. 기여 노름 $c_j = \tilde{g}_j \cdot \|W_d[:,j]\| \cdot \|W_u[j,:]\|$ 상위 k개 뉴런을 **정적 hot set으로 마스크에 상시 포함**(비용 = sparsity를 k/d만큼 양보)하면, 보상 대상이 M_{cold} 로 줄고 스펙트럼이 덜 flat해질 수 있다. 같은 랩의 overlap 연구("top-10% 고빈도 pool은 s에 걸쳐 일관, overlap 0.68-0.91")와 정합적.

검증 실험(오프라인, GPU 몇 분): c_j 상위 $k=d/16$ 뉴런의 rank-1 항을 M에서 빼고 r90 재측정. r90가 크게 떨어지면 sweep 가치 있음, 안 떨어지면 기각 — PPL 실험 전에 갈 수 있는 초저비용 게이트.

제안 3 — 손실 정렬 목적함수로 A·B 적합 (Low-Rank Correction 템플릿)

템플릿: Low-Rank Correction(ICLR'25) — 폐형 SVD 대신 calibration 데이터에서 양자화 표현과 저rank 보정을 **공동 최적화**. EoRA는 입력 활성 고유공간 가중을 쓰는데, 이는 이번 실험이 기각한 "입력 분산 = 중요도" 가정과 같은 축이라 **대비 사례**로 인용.

이식: A, B를 SVD로 두지 말고 calibration에서 **블록 출력(또는 로짓) 재구성 오차를 직접 최소화**하도록 적합. 초저비용 1차 검증판: 양측 가중 SVD에서 입력 가중을 $\lambda^{(-\alpha)}$ 로 뒤집는 "anti-whitening" α -sweep — whitening이 해로웠다면 $\alpha > 0$ (저분산 우대)이 이득일 수 있는지 즉시 확인 가능.

보조 근거: MiLoRA(NAACL'25) "Least but not Last"(2026)는 가중치 스펙트럼의 minor/중간 특이성분이 기능적으로 중요함을 fine-tuning 맥락에서 보였다 — "작은 성분을 잘라도 된다"는 가정이 LLM에서 일반적으로 위험하다는 교차 증거. R-Sparse(ICLR'25)의 저rank 보상이 성공한 것은 보상 대상이 "저크기 입력 채널의 잔차"로 작았기 때문 — 우리의 M은 출력의 주 성분이라 같은 rank로는 부족했다는 해석과 일관.

다음 단계 (제안 — 미투입)

- **0순위 (초저비용 게이트):** 제안 2의 오프라인 진단(hot-set 제거 후 r90) + 제안 3의 anti-whitening α -sweep factor 구성 — 각각 GPU 몇 분.
- **1순위:** 제안 1 — M 4/8-bit 양자화 C4 재실행 $\times 3s$ (잡 1개). 성공 시 배포형 확정.
- **참조선:** plain 균일 $r=2048$ (+12.4%): 같은 MAC 예산에서 양자화 M과 직접 비교.
- **일반화:** 배포형이 성립하면 LLaMA3-8B / 타 family로 확장 (백로그).

Reproducibility

```

job 050-20260723-155254-oracle-llama2-phase0-calib · tag exp/2026-07-22_oracle-llama2-phase0-calib ·
commit 6bf95b1 · seed 42
calibration: c4-en + wikitext-103, 각 512×2048 tok · phase-0: 32 seq · 산출물: a100-40-
2:~/workspace/oracle/llama2-7b/{stats, phase0, factors/r512}
phase 3-4: jobs 050-20260724-021237 (dense+c1) · 050-20260724-040432 (c2/c3/c4/c5) · tags exp/2026-07-
23_...phase3-c0c1, exp/2026-07-24_...phase4-c2c5 (36b39ee) · a6000-2 GPU0, venv (torch 2.6.0+cu124,
transformers 4.46.3, sdpa) · select=topk K=int((1-s)d)
실험 카드: .labtool/topics/oracle-residual-sparsity/journal/ — phase0-calib, phase3-c0c1, phase4-c2c5

```